PROJETO FINAL – DISCIPLINA BIOMETRIA

Sistemas Biométricos Baseados em Redes Neurais Convolucionais

Modalidades: Face, Impressão Digital, Íris e Voz

Equipe: trabalho em dupla / **Data de Entrega**: 18 ou 25/11/2026

Entrega final: artigo científico + link para a implementação + apresentação

1. Objetivo do Projeto

O Projeto Final tem o objetivo de desenvolver, avaliar e comparar sistemas biométricos baseados em Redes Neurais Convolucionais (CNNs), utilizando protocolos experimentais comuns e reprodutíveis. O foco principal será a verificação biométrica 1:1, baseada na geração de *embeddings* e na comparação de similaridade entre amostras.

A proposta foi estruturada para que os resultados produzidos pelas diferentes duplas possam ser consolidados posteriormente em um estudo comparativo, permitindo investigar o efeito da arquitetura da CNN, do dataset, da generalização entre bases e da robustez do sistema.

Questão central: o objetivo não é simplesmente obter a maior acurácia possível, mas produzir um experimento biométrico correto, reproduzível, comparável e cientificamente defensável.

2. Organização e distribuição das duplas

O projeto será desenvolvido em dupla. Cada modalidade biométrica será atribuída a duas duplas. As duas duplas da mesma modalidade deverão utilizar famílias de CNN diferentes e avaliar seus modelos nas duas bases associadas à modalidade.

Dupla	Modalidade	Base principal	Segunda base
1	Face	LFW	CFP-FP
2	Face	CFP-FP	LFW
3	Impressão Digital	FVC2002 DB1	FVC2004 DB1
4	Impressão Digital	FVC2004 DB1	FVC2002 DB1

Dupla	Modalidade	Base principal	Segunda base
5	Íris	CASIA-Iris-V3 Interval	IIT Delhi Iris
6	Íris	IIT Delhi Iris	CASIA-Iris-V3 Interval
7	Voz	VCTK	LibriSpeech train-clean-100
8	Voz	LibriSpeech train-clean-100	VCTK

A base principal será utilizada no desenvolvimento inicial, treinamento ou fine-tuning (quando aplicável) e validação do sistema. Em seguida, o mesmo sistema deverá ser avaliado também na segunda base, permitindo análise cross-dataset.

3. Pergunta central de pesquisa

Os projetos deverão contribuir para responder à seguinte questão:

Como diferentes arquiteturas CNN se comportam em diferentes bases de uma mesma modalidade biométrica, considerando desempenho, custo computacional, robustez e capacidade de generalização?

	Dataset A	Dataset B
CNN da Dupla A	✓	✓
CNN da Dupla B	✓	✓

4. Escolha da CNN

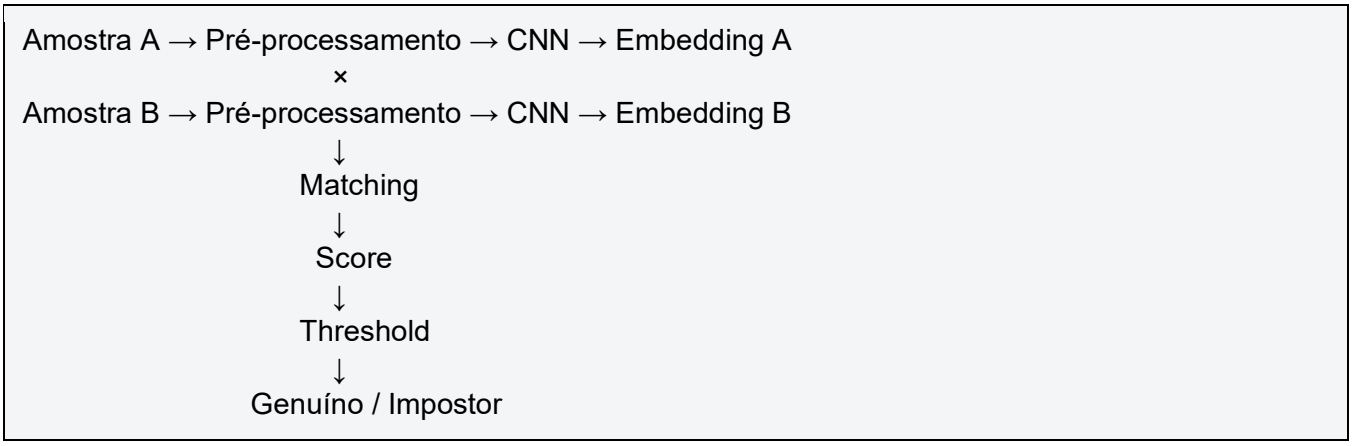
A arquitetura será escolhida pela própria dupla. Entretanto, as duas duplas que trabalham com a mesma modalidade biométrica não poderão utilizar a mesma família de CNN.

- Exemplo aceitável: ResNet50 versus EfficientNet-B0; MobileNetV3 versus ConvNeXt-Tiny.
- Exemplo não recomendado: ResNet18 versus ResNet34, pois pertencem à mesma família.
- A arquitetura deverá ser registrada com o professor antes do início dos experimentos para evitar duplicidade.
- São permitidos modelos pré-treinados, *transfer learning*, *fine-tuning*, redes siamesas, Contrastive Loss, Triplet Loss, ArcFace/CosFace e outras estratégias devidamente justificadas.

A dupla deverá declarar no artigo e no repositório: arquitetura, origem dos pesos, dataset de pré-treinamento, camadas congeladas, camadas treinadas, função de perda, dimensão do *embedding* e número de parâmetros do modelo.

5. Requisitos

Não será suficiente implementar uma CNN classificadora que apenas retorne diretamente o nome ou a classe do indivíduo. O sistema deverá gerar uma representação biométrica (template/*embedding*) e realizar *matching* entre duas amostras.



6. Pipeline obrigatório



Na apresentação e no artigo deverão ser mostrados exemplos reais das principais etapas do pipeline, sempre que aplicável à modalidade.

7. Pré-processamento padronizado por modalidade

Para tornar a comparação entre CNNs mais justa, as duas duplas da mesma modalidade deverão utilizar, tanto quanto possível, o mesmo pré-processamento. Caso uma etapa seja alterada, a diferença deverá ser claramente documentada e justificada.

Modalidade	Pipeline mínimo recomendado
Face	detecção → alinhamento por landmarks → recorte → normalização
Impressão Digital	ROI → escala de cinza → normalização → redimensionamento
Íris	segmentação → pupila/limbo → Rubber Sheet → normalização
Voz	mono 16 kHz → VAD/remoção de silêncio → log-Mel spectrogram → normalização

A intenção é reduzir o risco de atribuir à CNN uma vantagem que, na realidade, tenha sido causada por um pré-processamento mais favorável.

8. *Matching* padronizado

Como métrica de referência, deverá ser utilizada a similaridade de cosseno entre embeddings normalizados. Caso a literatura da arquitetura escolhida recomende outra métrica, ela poderá ser utilizada adicionalmente, mas os resultados com similaridade de cosseno deverão ser preservados para comparação entre as duplas.

Interpretação padrão: quanto maior a similaridade de cosseno, maior a semelhança entre as duas amostras biométricas.

9. Separação treinamento, validação e teste

Quando houver treinamento ou fine-tuning, treinamento, validação e teste deverão ser mutuamente exclusivos por identidade. A divisão nunca deverá ser feita apenas por imagem ou amostra.

INCORRETO:
João_1 → treino
João_2 → treino
João_3 → teste

CORRETO:
João / Maria / Pedro → treino
Carlos → validação
Ana / José / Lucas → teste

Essa regra evita *identity leakage* e resultados artificialmente inflados.

10. Regras específicas por modalidade

10.1 Íris

Olho esquerdo e olho direito serão considerados identidades biométricas distintas. Assim, o olho esquerdo de um indivíduo não forma par genuíno com o olho direito do mesmo indivíduo.

10.2 Voz

O problema é Speaker Verification, e não reconhecimento do conteúdo falado. O objetivo é responder “é a mesma pessoa falando?”, e não “o que a pessoa falou?”. A representação de entrada deverá ser documentada, sendo recomendado o uso de log-Mel spectrogram ou representação equivalente.

11. Formação dos pares genuínos e impostores

Cada dataset deverá gerar dois tipos de comparação:

- Par genuíno: duas amostras da mesma identidade biométrica.
- Par impostor: duas amostras pertencentes a identidades biométricas diferentes.

Todos os scores deverão ser armazenados. Exemplo de arquivo scores.csv:

```
amostra_1,amostra_2,tipo,score
001_1.jpg,001_2.jpg,genuine,0.8721
001_1.jpg,053_2.jpg,impostor,0.2419
```

Os mesmos pares deverão ser utilizados pelas duas CNNs avaliadas em uma mesma base.

12. Protocol comum

Sempre que a base possuir protocolo oficial de avaliação, ele deverá ser utilizado prioritariamente. Nos demais casos, as divisões e os pares serão definidos por um protocolo comum, com semente fixa, para assegurar a reprodutibilidade.

```
protocols/
├── train.csv
├── validation.csv
├── test.csv
├── genuine_pairs.csv
└── impostor_pairs.csv

seed = 42
```

13. Definição do threshold

O conjunto de teste não poderá ser utilizado para escolher threshold ou hiperparâmetros. O limiar deverá ser definido exclusivamente com dados de validação e então congelado antes da avaliação final.

```
VALIDAÇÃO → scores genuínos + impostores → definição do threshold
                                ↓
                            CONGELA
                                ↓
                             TESTE
```

14. Métricas obrigatórias

Métrica / informação	Obrigatória?	Observação
FMR/FAR	Sim	Taxa de falsas aceitações/matches
FNMR/FRR	Sim	Taxa de falsas rejeições/non-matches
EER	Sim	Ponto em que FMR e FNMR se igualam
ROC	Sim	Curva de desempenho em diferentes limiares

Métrica / informação	Obrigatória?	Observação
AUC	Sim	Área sob a curva ROC
Distribuição genuíno × impostor	Sim	Histograma ou densidade dos scores
TAR@FAR=1%	Quando viável	Depende da quantidade de comparações impostoras
Tempo médio de inferência	Sim	Registrar hardware
Número de parâmetros	Sim	Complexidade do modelo
Tamanho do modelo	Sim	Arquivo/pesos do modelo
FTA — Failure to Acquire	Quando aplicável	Falhas antes do matching
Rank-1 / CMC	Opcional	Somente se houver experimento 1:N

15. Gráficos obrigatórios: distribuição de scores

O artigo deverá apresentar a distribuição dos scores genuínos e impostores, com indicação do *threshold* utilizado. O objetivo é visualizar a separação entre as classes e compreender erros que uma única medida de acurácia não revela.

16. Experimentos obrigatórios

16.1 Experimento A – desempenho na base principal

Cada dupla deverá inicialmente desenvolver e avaliar sua CNN na base principal atribuída.

16.2 Experimento B – 2 CNNs x 2 datasets

As duas CNNs de uma modalidade deverão ser avaliadas nas duas bases correspondentes. Essa matriz de resultados permitirá investigar se a arquitetura mantém seu desempenho quando o dataset muda.

	Dataset A	Dataset B
CNN da Dupla A	✓	✓
CNN da Dupla B	✓	✓

16.3 Experimento C – cross dataset

O modelo desenvolvido ou ajustado na base de origem deverá ser congelado e avaliado na base de destino sem novo *fine-tuning*. Esse experimento mede capacidade de generalização e sensibilidade a diferenças de sensor, protocolo e domínio.

Base A → desenvolvimento / fine-tuning → modelo congelado → Base B → avaliação

16.4 Experimento D - robustez

Modalidade	Perturbação mínima sugerida
Face	blur e/ou oclusão
Impressão Digital	blur e/ou rotação
Íris	blur e/ou oclusão
Voz	ruído aditivo

Deverão ser avaliados, no mínimo, quatro níveis: original, baixa degradação, média degradação e alta degradação. O artigo deverá discutir como o desempenho biométrico se altera conforme a qualidade da amostra diminui.

16.5 Estudo de ablação

Cada dupla deverá realizar um estudo de ablação simples, removendo ou modificando uma etapa do pipeline para verificar sua contribuição real. Exemplos: face com/sem alinhamento; íris com/sem Rubber Sheet; voz com/sem VAD; impressão digital com/sem normalização.

17. Repetição experimental

Para modelos efetivamente treinados ou ajustados, recomenda-se executar o treinamento três vezes com sementes diferentes (por exemplo: 42, 123 e 2026) e reportar

média e desvio-padrão. Esse procedimento evita interpretar pequenas diferenças aleatórias como melhoria real.

18. Eficiência computacional

A comparação não deverá considerar apenas desempenho biométrico. Também deverão ser reportados custo e eficiência do modelo: número de parâmetros, tamanho dos pesos, tempo de inferência e hardware utilizado. A discussão deverá considerar se pequenas melhorias de EER justificam aumentos expressivos de custo computacional.

19. Análise dos erros

Cada dupla deverá selecionar pelo menos três falsos matches e três falsos non-matches. Para cada caso, o artigo deverá apresentar as amostras (ou representação equivalente, no caso de voz), score, *threshold* e uma hipótese técnica para a causa do erro.

Modalidade	Possíveis causas a investigar
Face	pose, iluminação, idade, oclusão, alinhamento
Impressão Digital	captura parcial, rotação, baixa qualidade, ruído
Íris	segmentação, reflexos, pálpebra, cílios, dilatação
Voz	ruído, microfone, duração, canal, condição vocal

20. Entrega Final

A entrega formal será composta por apenas dois produtos principais:

1. Artigo científico em PDF.
2. Link para o repositório contendo a implementação utilizada para produzir os resultados apresentados no artigo.

   Todo resultado apresentado no artigo deverá poder ser reproduzido a partir do código disponibilizado no repositório.

3. Apresentação para a turma de 10 minutos, devendo conter metodologia, resultados e discussões.

21. Artigo científico

O artigo será o documento principal de avaliação e deverá apresentar o trabalho como investigação científica, e não como simples relatório de programação. Recomenda-se

extensão de 6 a 8 páginas, além das referências, em template único a ser definido pelo professor (por exemplo, SBC ou IEEE).

Seção	Conteúdo mínimo
1. Introdução	problema, modalidade, motivação, objetivo e contribuição
2. Trabalhos relacionados	métodos da literatura, CNNs e resultados de referência
3. Base de dados	indivíduos, amostras, aquisição, protocolo e exemplos
4. Metodologia	pipeline, pré-processamento, CNN, treinamento/fine-tuning, embedding e matching
5. Protocolo experimental	divisões, pares, seeds, hardware, threshold, cross-dataset e robustez
6. Resultados	EER, FMR, FNMR, ROC/AUC, distribuições, eficiência e demais métricas
7. Análise e discussão	erros, cross-dataset, robustez, comparação, limitações
8. Conclusão	síntese dos achados e perspectivas
Referências	fontes científicas adequadas e atualizadas

O artigo deverá permitir que um leitor compreenda e, em princípio, reproduza integralmente o experimento realizado.

22. Repositório da implementação

O artigo deverá informar o endereço do repositório (GitHub, GitLab ou equivalente). O repositório deverá conter, no mínimo, os arquivos necessários para reproduzir o pipeline e os resultados.

```
projeto/
├── README.md
├── requirements.txt
├── config.yaml
├── preprocess.py
├── model.py
├── train.py
├── extract_embeddings.py
├── evaluate.py
├── robustness.py
├── protocols/
│   ├── train.csv
│   ├── validation.csv
│   └── test_pairs.csv
└── results/
    ├── scores.csv
    ├── metrics.json
    ├── roc.png
    └── distributions.png
```

Os datasets originais não deverão ser redistribuídos no repositório. O README deverá explicar onde obtê-los legalmente e como organizá-los localmente.

23. Conteúdo do README

- Modalidade biométrica e dataset(s).
- CNN utilizada e origem dos pesos.
- Dataset de pré-treinamento, quando aplicável.
- Pré-processamento e formato de entrada.
- Dimensão do embedding.
- Função de perda e estratégia de treinamento/fine-tuning.
- Método de matching e regra de threshold.
- Versão do Python e bibliotecas.
- Hardware utilizado.
- Seeds utilizadas.
- Comandos para executar o pipeline e reproduzir os resultados do artigo.

24. Congelamento da versão entregue

Na data da entrega, a dupla deverá informar o link do repositório e o identificador exato da versão avaliada, por meio de tag ou hash de commit. Isso garante que a implementação utilizada na correção seja exatamente a que produziu os resultados do artigo.

Repositório: https://...
Versão avaliada: tag final-v1.0
ou
Commit: a82b7f1

25. Arquivos de resultados

O repositório deverá incluir, sempre que possível, os arquivos scores.csv e metrics.json correspondentes à versão final. Esses arquivos serão utilizados para consolidar posteriormente os resultados das diferentes duplas sem necessidade de reexecutar todos os modelos.

26. Tabela padronizada de resultados

Informação	Resultado
Modalidade	
Dataset	
CNN	
Pré-treinamento	
Nº de parâmetros	
Dimensão do embedding	
Matching	
Threshold	
EER	
AUC	
FMR	
FNMR	
TAR@FAR=1%	

Informação	Resultado
FTA	
Tempo de inferência	
Tamanho do modelo	
Hardware	

27. Apresentação e defesa

A apresentação final funcionará como defesa do artigo e demonstração do sistema, mas não será considerada uma terceira entrega formal. Sugestão de tempo: 10 minutos de apresentação + 5 minutos de arguição.

A apresentação deverá seguir, preferencialmente, esta sequência: problema → dataset → pipeline → CNN → embedding → matching → protocolo → resultados → cross-dataset → robustez → erros → conclusões.

28. Critérios de avaliação

Critério
Implementação e funcionamento do sistema
Correção do protocolo experimental
CNN, embedding e matching
Métricas e análise dos scores
Experimento cross-dataset
Robustez e estudo de ablação
Análise crítica dos erros
Reprodutibilidade da implementação
Qualidade do artigo e da apresentação
TOTAL

29. Regras gerais do projeto

1. O projeto será desenvolvido em dupla.
2. Cada dupla receberá uma modalidade biométrica e uma base principal.
3. As duas duplas da mesma modalidade deverão utilizar CNNs de famílias diferentes.
4. A CNN deverá produzir embeddings biométricos; classificação direta por identidade não será suficiente.
5. A tarefa principal será verificação biométrica 1:1.
6. Não será permitida mistura de identidades entre treino, validação e teste.
7. O conjunto de teste não poderá ser usado para escolher threshold ou hiperparâmetros.
8. Os mesmos pares de avaliação deverão ser usados pelas duas CNNs em uma mesma base.
9. As métricas obrigatórias incluem EER, FMR, FNMR, ROC, AUC e distribuição de scores.
10. O sistema deverá ser avaliado na base principal e na segunda base da modalidade.
11. O experimento cross-dataset deverá ser realizado sem novo fine-tuning na base de destino.
12. Deverá ser realizado pelo menos um experimento de robustez e um estudo de ablação.
13. Pelo menos três falsos matches e três falsos non-matches deverão ser analisados.
14. Uso de modelos pré-treinados é permitido, desde que origem, pesos e dataset de pré-treinamento sejam declarados.
15. Os datasets originais não deverão ser redistribuídos no repositório.
16. Todo resultado do artigo deverá ser reproduzível pelo código entregue.
17. A versão final deverá ser identificada por tag ou hash de commit.
18. Resultados negativos são válidos quando o protocolo é correto e a análise é tecnicamente consistente.